Proyecto Final de Deep Learning: Entregable 1

Estado del Arte, EDA e Implementación de los Tres Modelos Base de la Literatura

Objetivo del Entregable

Identificar el estado del arte en Deep Learning para el problema de aplicación seleccionado, realizar un EDA exhaustivo, **extraer de la literatura los tres modelos de Deep Learning más básicos que se emplean como referencia comparativa para dicho problema** e **implementarlos** con rigor experimental, garantizando reproducibilidad y ausencia de *data leakage*. El propósito final es **establecer, con evidencia estadística, el nivel mínimo de desempeño (*baseline*) en error o precisión** que cualquier modelo avanzado deberá superar para justificar su mayor complejidad.

Estructura del proyecto y cómo leer este documento

El proyecto consta de tres entregables encadenados: el **Entregable 1** (este documento) establece el baseline con tres modelos; el **Entregable 2** escala a un benchmark de 10 modelos con inferencia estadística formal; el **Entregable 3** lleva los resultados a producción y aporta un modelo original. Los resultados, el *pipeline*, las particiones y el *dataset* definidos aquí se **reutilizan** en los entregables siguientes: cualquier decisión tomada en este documento debe poder sostenerse en ellos.

- Las Secciones 1 a 5 definen **qué** debe entregarse.
- La Sección 6 define **cómo proceder** según el tipo de problema.
- La Sección 7 aclara las limitaciones inferenciales de trabajar con solo tres modelos.

Donde una sección posterior precise a una anterior, **prevalece la más restrictiva**.

Tipos de problema admitidos

Solo se aceptan proyectos cuyos datos correspondan a **uno** de los siguientes diez tipos de problema:

1. Clasificación (datos tabulares).
2. Regresión (datos tabulares).
3. Series de tiempo (pronóstico de una serie a partir de su propio pasado, con o sin covariables).
4. Regresión temporal (objetivo continuo que depende de covariables observadas en el tiempo, sin que el pronóstico se base en la autorregresión del objetivo).
5. Regresión espacial.
6. Regresión espacio-temporal.
7. Clasificación de imágenes.
8. Segmentación de imágenes.
9. Clasificación de texto.
10. Etiquetado secuencial (*sequence labeling*) y aprendizaje secuencia a secuencia (*sequence-to-sequence*), tratados como dos tipos distintos con rutas separadas en el Entregable 2.

Diferencia entre series de tiempo y regresión temporal. En *series de tiempo* el objetivo es pronosticar valores futuros de una serie usando su propia historia (rezagos del objetivo), con o sin covariables exógenas; el orden temporal y la autocorrelación son la estructura central. En *regresión temporal* el objetivo se explica por covariables medidas en el mismo instante o con rezagos de las covariables, y no se utiliza la historia del objetivo como entrada; los datos tienen marca de tiempo, pero el problema se evalúa como una regresión con partición cronológica. Si el proyecto usa rezagos del objetivo como entrada, **es** series de tiempo.
Cualquier proyecto fuera de esta lista no será evaluado. El tipo de problema elegido determina las secciones del EDA, las arquitecturas base candidatas, el esquema de partición, las métricas y las pruebas estadísticas que deben aplicarse (véase la Sección 6, *Guía de Procedimiento por Tipo de Problema*). Cada tipo tiene su ruta metodológica completa en la Sección 7 del Entregable 2.

1. Definición del Problema y Dataset

- **Definición formal del problema:**
  - Enunciar el problema en notación matemática: espacio de entrada $\mathcal{X}$, espacio de salida

$\mathcal{Y}$, función objetivo $f : \mathcal{X} \to \mathcal{Y}$ y función de pérdida $\mathcal{L}$ que se minimiza.

- Declarar explícitamente a cuál de los diez tipos de problema admitidos pertenece el proyecto.
- Declarar la pregunta de investigación y la hipótesis operativa que el benchmark permitirá contrastar.
- **Declarar a priori** la métrica primaria, las métricas secundarias, el margen de relevancia práctica δ y la unidad de independencia (paciente, documento, autor, cliente, serie, escena); estas decisiones se heredan en los Entregables 2 y 3.

- **Justificación del dataset:**
  - Relevancia científica o aplicada del problema.
  - Disponibilidad pública, licencia de uso y procedencia (proceso de generación y recolección de los datos).
  - Uso previo del dataset en la literatura revisada, de modo que los resultados sean comparables.
- **Descripción técnica:**
  - Tamaño y estructura (número de observaciones, dimensionalidad, formato de almacenamiento).
  - Tipo de datos y unidad de observación.
  - Variable objetivo y su proceso de etiquetado (manual, automático, medición instrumental), incluyendo el ruido de etiqueta esperado.
  - Estructura de dependencia entre observaciones (independientes, agrupadas por sujeto, sitio o documento; temporales; espaciales). Esta estructura condiciona la partición y la inferencia estadística posterior.
  - Versión del dataset y *hash* o suma de verificación para trazabilidad.

2. Análisis Exploratorio de Datos (EDA) Mejorado

El EDA debe ser **exhaustivo, reproducible y orientado a decisiones de modelado**. Cada análisis debe responder explícitamente: *¿cómo impacta esto el diseño del modelo, el preprocesamiento o el esquema de validación?* No se aceptan análisis descriptivos sin interpretación técnica.

2.1 EDA General (aplica a todos los tipos de problema)

- **Análisis de la variable objetivo:**
  - Distribución (histogramas, densidades, conteos por clase o por etiqueta).
  - Cuantificar el desbalance (razón entre clase mayoritaria y minoritaria; entropía de la distribución de clases).
  - Detectar clases raras, colas pesadas, asimetría y curtosis (en objetivos continuos).
  - Implicación: *resampling*, ponderación de pérdidas, transformación del objetivo (log, Box–Cox) o métricas robustas.
- **Calidad del dataset:**
  - Valores faltantes: cuantificar y caracterizar el mecanismo (MCAR, MAR, MNAR) con evidencia, no solo conteos.
  - Datos corruptos, inconsistentes o fuera de rango físico o semántico.
  - Duplicados exactos y casi duplicados (críticos en imágenes y texto, pues generan fuga entre particiones).
  - Ruido de etiquetas: estimación mediante inspección muestral o acuerdo entre anotadores, cuando aplique.
- **Identificación de sesgos y desplazamientos de distribución:**
  - Sesgos de representación (clases o subpoblaciones dominantes).
  - Sesgos temporales y espaciales (cambios de régimen, autocorrelación espacial).
  - Sesgos semánticos o de dominio (NLP, imágenes de distintas fuentes o sensores).
  - Correlaciones espurias entre atributos irrelevantes y la etiqueta (*shortcut learning*).
  - Prueba de desplazamiento de covariables entre las particiones propuestas (por ejemplo, clasificador adversarial o pruebas de dos muestras).
  - Implicación: balanceo, recolección adicional, validación estratificada o agrupada.
- **Partición del dataset:**
  - Definir explícitamente los conjuntos de entrenamiento, validación y prueba, con proporciones y semilla.
  - Justificar la estrategia según la estructura de dependencia de los datos: aleatoria, estratificada, agrupada, temporal o espacial por bloques.
  - Verificar que la distribución de la variable objetivo y de las covariables principales sea consistente entre particiones.

- Congelar el conjunto de prueba (almacenar su *hash*): no se consulta durante el ajuste de hiperparámetros ni durante el diseño del preprocesamiento.

2.2 EDA Específico por Tipo de Problema

Realice únicamente el bloque de EDA que corresponda al tipo de problema elegido. Si el problema combina modalidades (por ejemplo, imágenes con metadatos tabulares), aplique cada bloque pertinente.

A. Clasificación y Regresión (datos tabulares)

- **Estructura de atributos:**
  - Tipificación de variables (numéricas, categóricas nominales y ordinales), cardinalidad y escalas.
  - Distribuciones univariadas, asimetría y valores atípicos (criterio explícito: rango intercuartílico, distancia de Mahalanobis o métodos robustos).
  - Implicación: transformación, escalado robusto, codificación (one-hot, *embeddings* de entidades).
- **Relación entre atributos y objetivo:**
  - Correlaciones lineales y de rango (Pearson, Spearman) e información mutua para relaciones no lineales.
  - Multicolinealidad (factor de inflación de varianza, número de condición).
  - Detección de atributos con fuga de información hacia el objetivo (atributos derivados de la etiqueta o registrados posteriormente al evento).
- **Complejidad de la tarea:**
  - Estimar la separabilidad o linealidad inicial ajustando un modelo lineal de referencia (regresión logística o lineal regularizada) para dimensionar el margen de mejora disponible.
- **Implicaciones clave:** diseño de MLP (profundidad, ancho, regularización), manejo de variables categóricas, función de pérdida (entropía cruzada ponderada, Huber, error cuadrático) y partición estratificada o agrupada.

B. Series de Tiempo

- **Visualización y descomposición:**

    - Gráfico de la serie y descomposición (STL o equivalente) en tendencia, estacionalidad (puede ser múltiple) y residuo.
    - Detección de cambios de régimen y puntos de quiebre.
- **Estacionariedad:**
    - Pruebas ADF y KPSS usadas de forma conjunta, interpretando los cuatro escenarios posibles de concordancia o conflicto entre ambas.
    - Implicación: diferenciación, transformación logarítmica o de potencia, normalización por ventana.
- **Dependencia temporal:**
    - ACF y PACF con bandas de confianza; periodograma o análisis espectral para periodicidades.
    - Identificación de rezagos relevantes que justifiquen la longitud de la ventana de entrada.
    - Evaluación de no linealidad y heterocedasticidad (por ejemplo, prueba ARCH).
- **Frecuencia, granularidad y datos faltantes:**
    - Intervalo de muestreo, regularidad y huecos temporales; política de imputación que no use información futura.
    - Series múltiples: heterogeneidad entre series y decisión entre modelo local, global o multivariado.
- **Outliers y anomalías:** detección, causa probable y evaluación de su impacto sobre el error.
- **Implicaciones clave:**
    - Definición del horizonte de pronóstico h (un paso o multi-paso) y de la longitud de la ventana de entrada.
    - Estrategia multi-paso (recursiva, directa o multi-salida).
    - Partición cronológica estricta y validación con origen móvil (*rolling-origin*); escalado ajustado solo con el pasado.
    - Riesgo principal: **data leakage temporal**.

C. Regresión Temporal

- **Estructura temporal de las covariables:**

  - Frecuencia, regularidad y huecos de las covariables; desfases entre la marca de tiempo de las covariables y la del objetivo.
  - Disponibilidad de cada covariable **en el momento de la predicción** (una covariable que solo se conoce después del evento es fuga).
- **Relación covariables–objetivo en el tiempo:**
  - Correlaciones cruzadas con rezagos de las covariables; identificación de desfases informativos.
  - Deriva de la relación (cambios de régimen, relaciones no estacionarias) mediante estimaciones en ventanas móviles.
  - Diagnóstico de autocorrelación de los residuos de un modelo de referencia, para decidir si el problema es realmente de regresión temporal o necesita rezagos del objetivo (en cuyo caso corresponde a series de tiempo).
- **Implicaciones clave:** ventana de rezagos de las covariables, partición cronológica estricta con *embargo*, escalado ajustado solo con el pasado y riesgo de **fuga temporal**.

D. Regresión Espacial

- **Estructura geográfica:**
  - Mapa de ubicaciones y de la variable objetivo; cobertura espacial y densidad de muestreo (agrupamientos y vacíos).
  - Sistema de coordenadas y proyección empleados.
- **Autocorrelación espacial:**
  - Índice I de Moran (global y local, LISA) y/o C de Geary, con definición explícita de la matriz de pesos espaciales.
  - Semivariograma empírico: rango, *sill* y efecto *nugget*.
  - Implicación: distancia de decorrelación que determina el tamaño de los bloques de validación.
- **Covariables:** estacionariedad espacial de las relaciones (posible heterogeneidad espacial), multicolinealidad y calidad por ubicación.
- **Implicaciones clave:**
  - Representación de la posición (coordenadas, *embeddings* posicionales, grafo de vecindad).

- Partición por bloques espaciales con separación (*buffer*) mayor al rango del semivariograma.
- Riesgo principal: **fuga espacial**, que infla el desempeño con particiones aleatorias.

E. Regresión Espacio-Temporal

- **Estructura conjunta:**
  - Estructura del tensor de datos (nodos o celdas × tiempo × atributos) y régimen de observación (rejilla regular, red de sensores, grafo).
  - Análisis de cada marginal: perfil temporal por ubicación (análisis tipo B) y mapa por instante (análisis tipo D).
- **Dependencia espacio-temporal:**
  - Autocorrelación espacio-temporal (por ejemplo, I de Moran espacio-temporal, correlación cruzada con rezagos entre vecinos, variogramas espacio-temporales).
  - Estacionariedad y separabilidad espacio-temporal; propagación o difusión entre ubicaciones.
- **Datos faltantes y heterogeneidad:** patrones de faltantes por sensor y por tiempo; ubicaciones con dinámicas atípicas.
- **Implicaciones clave:**
  - Construcción del grafo o de la rejilla (criterio de vecindad: distancia, adyacencia o correlación).
  - Elección de arquitecturas base que combinen componente temporal y espacial.
  - Partición temporal estricta; si se evalúa generalización a ubicaciones nuevas, además partición por bloques espaciales.
  - Riesgos: **fuga temporal y fuga espacial** de forma simultánea.

F. Clasificación de Imágenes

- **Inspección visual:**
  - Muestras aleatorias estratificadas por clase; identificación de ruido, artefactos, marcas de agua y errores de etiquetado.
  - Detección de atajos visuales (fondos, bordes o metadatos correlacionados con la clase).
- **Dimensionalidad y formato:**

  - Distribución de alto, ancho y relación de aspecto; número de canales y profundidad de bits.
  - Implicación: *resizing*, recorte o *padding*, normalización.
- **Estadísticos de intensidad:**
  - Histogramas por canal; media y desviación estándar por canal calculadas solo con el conjunto de entrenamiento.
  - Detección de saturación, bajo contraste y diferencias de adquisición entre clases.
- **Balance y duplicados:**
  - Conteo por clase; implicación en *data augmentation*, *class weighting* o muestreo balanceado.
  - Detección de duplicados y casi duplicados mediante *hashing* perceptual o similitud de *embeddings*, y eliminación de fugas entre particiones.
- **Estructura de agrupamiento:** si existen varias imágenes por sujeto, paciente, sitio o secuencia, la partición debe ser agrupada.
- **Implicaciones clave:** resolución de entrada, *augmentations* admisibles (que preserven la etiqueta), profundidad de la CNN base y estrategia de partición.

G. Segmentación de Imágenes

- **Inspección visual de imágenes y máscaras:**
  - Superposición de máscaras sobre imágenes; verificación de alineación, calidad de bordes y consistencia entre anotadores.
  - Identificación de máscaras vacías, ruidosas o inconsistentes.
- **Distribución de clases a nivel de píxel:**
  - Frecuencia de píxeles por clase, fracción de fondo y presencia de clases raras.
  - Distribución del tamaño, número y forma de las regiones (componentes conexas); tamaño relativo del objeto respecto a la imagen.
  - Implicación: pérdida basada en solapamiento (Dice, Tversky, *focal*) o ponderada, y muestreo de parches centrados en clases raras.
- **Dimensionalidad y formato:** resoluciones, canales y necesidad de recortes en parches (*tiling*); consistencia de resolución entre imagen y máscara.

- **Estadísticos de intensidad:** histogramas por canal y por clase; normalización con estadísticos del conjunto de entrenamiento.
- **Duplicados y agrupamiento:** detección de imágenes repetidas o solapadas (especialmente si provienen de mosaicos o recortes de una misma escena); partición por escena, sujeto o sitio.
- **Implicaciones clave:** profundidad del codificador–decodificador base, resolución de entrada, *augmentations* que se apliquen de manera consistente a imagen y máscara, y reporte de métricas por clase.

H. Clasificación de Texto

- **Longitud de textos:**
  - Distribución de longitud (en palabras y en *tokens* de subpalabra) y percentiles 90, 95 y 99.
  - Implicación: longitud máxima de secuencia, truncamiento o *padding*.
- **Análisis léxico:**
  - Frecuencias, ley de Zipf, términos discriminantes por clase (por ejemplo, información mutua o *log-odds*).
  - Detección de términos que actúan como atajos (nombres propios, fuentes, plantillas).
- **Tokenización y vocabulario:**
  - Tamaño de vocabulario, tasa de palabras fuera de vocabulario y comparación entre tokenización por palabra y por subpalabra.
  - Cobertura de los *embeddings* preentrenados candidatos sobre el vocabulario.
- **Ruido y calidad:** caracteres especiales, URLs, mayúsculas, *emojis*, *stopwords*, idioma mixto, errores ortográficos; decisión justificada de limpieza (no limpiar en exceso si la señal está en el formato).
- **Balance, duplicados y fuga semántica:**
  - Distribución de etiquetas; ratio de desbalance.
  - Duplicados exactos y casi duplicados (similitud de n-gramas o de *embeddings*) entre particiones.
  - Agrupamiento por autor, fuente o hilo cuando exista: la partición debe respetarlo.
- **Implicaciones clave:** tipo de representación (*embeddings* estáticos de palabra o subpalabra), longitud de secuencia y arquitectura base (CNN de texto, RNN, LSTM o GRU).

I. Etiquetado Secuencial

- **Esquema de etiquetas:**
  - Conjunto de etiquetas y formato (por ejemplo, BIO o BIOES); frecuencia por etiqueta y proporción de la etiqueta nula ("O").
  - Validez estructural de las secuencias de etiquetas (transiciones inválidas).
  - Implicación: métricas a nivel de entidad frente a nivel de *token* y restricciones de decodificación.
- **Estructura de las secuencias:**
  - Distribución de longitudes de oraciones o secuencias; longitud de los segmentos etiquetados (*spans*).
  - Análisis de *tokens* fuera de vocabulario y de ambigüedad (mismo *token* con múltiples etiquetas).
- **Dependencias entre etiquetas:** matriz de transición empírica entre etiquetas consecutivas; justificación de modelar o no dependencias de salida.
- **Calidad de anotación, duplicados y fuga:** consistencia de la anotación, oraciones repetidas entre particiones y partición por documento (no por oración suelta).
- **Implicaciones clave:** representación de entrada (palabra, carácter o subpalabra), arquitectura base (RNN, LSTM o GRU, con o sin capa de decodificación estructurada) y manejo del desbalance de la etiqueta nula.

J. Aprendizaje Secuencia a Secuencia

- **Longitudes de origen y destino:**
  - Distribución de longitudes de entrada y de salida, y su relación (razón de longitudes, correlación).
  - Implicación: longitudes máximas, *bucketing* y límites de decodificación.
- **Vocabularios:**
  - Tamaño, cobertura y tasa de palabras fuera de vocabulario en origen y destino; decisión de vocabulario compartido o separado y tipo de tokenización.
- **Calidad del alineamiento entre pares:** detección de pares desalineados, ruidosos o truncados; pares duplicados y pares casi duplicados entre particiones.

- **Distribución de contenido:** dominios, temas o estilos presentes; desplazamiento de dominio entre particiones.
- **Implicaciones clave:** arquitectura codificador–decodificador base, estrategia de entrenamiento (*teacher forcing*), estrategia de decodificación (voraz o por haz), métricas de generación y partición que evite fuga de pares o de documentos.

Requisito obligatorio
Cada análisis del EDA debe concluir con una sección explícita de:

- Decisión de preprocesamiento derivada.
- Impacto en la arquitectura del modelo.
- Riesgos identificados (incluyendo posibles fuentes de *data leakage*).

No se aceptan análisis descriptivos sin interpretación técnica.

3. Revisión del Estado del Arte y Extracción de los Tres Modelos Base

La revisión de literatura debe producir un único resultado central: la identificación de los **tres modelos de Deep Learning más básicos** que los estudios revisados emplean como referencia comparativa **para el problema de aplicación seleccionado**. La revisión debe basarse en literatura científica reciente (preferiblemente Q1 en WoS o Scopus) y ser trazable y reproducible.

3.1 Estrategia de Búsqueda (Obligatoria)

- **Cadena de búsqueda:** documentar las palabras clave y la cadena booleana completa (por ejemplo, "deep learning" AND "forecasting" AND "renewable energy"), con sinónimos y variantes terminológicas, la fecha de ejecución y el número de resultados de cada cadena.
- **Bases de datos consultadas:** WoS, Scopus e IEEE Xplore (y, de forma complementaria, arXiv para identificar tendencias recientes).
- **Periodo de búsqueda:** preferiblemente los últimos 5–8 años.
- **Criterios de inclusión y exclusión:**
  - Relevancia directa al problema de aplicación seleccionado.
  - Uso de Deep Learning.

- Métricas reportadas de forma verificable.
- Presencia de un modelo de referencia o línea base contra el cual se compara el modelo propuesto.
- Exclusión de estudios sin descripción suficiente de la arquitectura de referencia o del protocolo experimental.

- **Trazabilidad del proceso:** reportar el número de registros identificados, depurados, evaluados y finalmente incluidos, en un diagrama de flujo tipo PRISMA, e indicar quién realizó la selección y cómo se resolvieron los desacuerdos.
- **Evaluación de la calidad de los estudios:** valorar para cada estudio incluido la claridad del protocolo experimental, la ausencia aparente de fuga de datos, el número de repeticiones y el uso de pruebas estadísticas.

3.2 Identificación de los Tres Modelos Base de Deep Learning

Los tres modelos base deben **extraerse de la revisión de literatura**, a partir de los modelos de Deep Learning más sencillos que los estudios utilizan con fines comparativos **para resolver el problema de aplicación seleccionado**. Su función es equivalente a la que cumplen, en aprendizaje automático clásico, el **modelo logístico** en clasificación y la **regresión de vectores de soporte (SVR) con núcleo lineal** en regresión: establecer un nivel mínimo de desempeño que permita determinar cuánto error o precisión debe mejorar un modelo avanzado para ser considerado una contribución relevante.

- **Procedimiento de extracción:**

1. Revisar, en cada estudio incluido, qué modelos de Deep Learning se emplean como referencia o línea base.
2. Registrar para cada uno: tipo de arquitectura, profundidad, ancho, regularización y configuración de entrenamiento reportada.
3. Construir una tabla de frecuencia que indique cuántos estudios utilizan cada modelo como referencia.
4. Ordenar los candidatos por frecuencia de uso y por complejidad (número de parámetros y profundidad).
5. Seleccionar **exactamente tres modelos**: los más recurrentes y de menor complejidad arquitectónica, justificando la selección con las referencias que la respaldan.

6. Verificar que los tres modelos no sean redundantes entre sí (deben diferir en el sesgo inductivo que incorporan).

- **Criterios que debe cumplir cada modelo base:**
  - Arquitectura simple, reproducible y ampliamente documentada.
  - Uso frecuente como comparación en la literatura del problema elegido.
  - Capacidad de entrenarse bajo el mismo pipeline y la misma partición que los demás modelos base.
  - Ser un modelo de Deep Learning (no se aceptan como base modelos de aprendizaje automático clásico, que se emplean solo como referencia de contexto).
- **Producto obligatorio:** tabla de síntesis con las siguientes columnas: referencia, problema, dataset, modelos de Deep Learning básicos utilizados como referencia, métricas reportadas y valores obtenidos.
- **Justificación explícita** de la equivalencia entre los tres modelos base seleccionados y los modelos de referencia clásicos (modelo logístico en clasificación, SVR lineal en regresión), argumentando en términos de capacidad de representación, supuestos y propósito comparativo.
- **Si la literatura no define la arquitectura** de un modelo base (por ejemplo, se reporta solo "un MLP"), el estudiante **no la elige por criterio personal**: aplica la búsqueda de arquitectura del Entregable 2 (Sección 14), declarando el espacio antes de entrenar.

Familias de arquitecturas base candidatas según el tipo de problema
Las siguientes familias son punto de partida orientativo; la selección final debe provenir de la frecuencia observada en la literatura revisada.

- **Clasificación y regresión tabular:** perceptrón multicapa (MLP) superficial, MLP profundo con regularización, red residual para datos tabulares.
- **Series de tiempo:** MLP sobre ventana de rezagos, RNN simple, LSTM y GRU de una capa, CNN 1D / TCN poco profunda.
- **Regresión temporal:** MLP sobre covariables con rezagos, LSTM o GRU sobre secuencias de covariables, CNN 1D poco profunda sobre covariables.
- **Regresión espacial:** MLP con coordenadas y covariables, MLP con *embeddings* posicionales, CNN sobre rejilla de vecindad.
- **Regresión espacio-temporal:** LSTM o GRU global sobre ventanas, ConvLSTM, red convolucional sobre grafo o rejilla de poca profundidad.

- **Clasificación de imágenes:** CNN poco profunda (estilo LeNet o VGG reducida), CNN pequeña con normalización por lotes, ResNet de baja profundidad.
- **Segmentación de imágenes:** red totalmente convolucional (FCN) sencilla, codificador–decodificador convolucional básico, U-Net reducida.
- **Clasificación de texto:** MLP sobre *embeddings* promediados (tipo *fastText* con red), CNN de texto, LSTM o GRU unidireccional o bidireccional de una capa.
- **Etiquetado secuencial:** LSTM o GRU bidireccional con clasificación por *token*, la misma con capa de decodificación estructurada (CRF), CNN dilatada.
- **Secuencia a secuencia:** codificador–decodificador con GRU o LSTM, el mismo con mecanismo de atención aditiva, codificador–decodificador convolucional sencillo.

3.3 Análisis Detallado por Modelo Base

Para cada uno de los tres modelos base se debe incluir:

- **Referencias completas** de los artículos que lo respaldan como línea base (formato académico, con DOI).
- **Tipo de arquitectura:** MLP, RNN, LSTM, GRU, CNN, codificador–decodificador, etc.
- **Descripción técnica:**
  - Componentes principales, ecuaciones de las capas y flujo de datos (con diagrama).
  - Supuestos de modelado y sesgo inductivo.
  - Función de pérdida y procedimiento de optimización habituales.
- **Tipo de problema que aborda.**
- **Dataset(s) utilizados** en los artículos donde se emplea como referencia.
- **Métricas reportadas** y valores obtenidos en la literatura, indicando si incluyen medidas de dispersión.
- **Fortalezas:** simplicidad, eficiencia, facilidad de reproducción.
- **Limitaciones:** capacidad de representación, sobreajuste, sensibilidad a hiperparámetros.
- **Complejidad computacional:**
  - Número de parámetros (con expresión analítica en función de los hiperparámetros).
  - Costo por paso de entrenamiento y de inferencia (orden de complejidad).

- Tiempo de entrenamiento, si se reporta.

3.4 Comparación Crítica

- Comparación estructurada entre los tres modelos base:
  - Desempeño reportado en la literatura.
  - Robustez.
  - Escalabilidad.
- Análisis crítico de la validez de los estudios revisados: protocolos de partición, riesgo de fuga, número de repeticiones, ausencia de pruebas estadísticas y comparabilidad entre conjuntos de datos.
- Análisis de la brecha de desempeño que la literatura reporta entre los modelos avanzados y estos modelos base, como contexto para interpretar el baseline obtenido.
- Identificación de **gap en la literatura**, formulado como una brecha concreta y verificable (por ejemplo, "ningún estudio incluido compara X contra Y bajo la condición Z con inferencia estadística").

No se acepta una revisión descriptiva superficial. Se espera **análisis crítico comparativo** y justificación clara de los tres modelos base extraídos.

4. Implementación y Evaluación de los Tres Modelos Base

Los tres modelos base extraídos de la literatura deben ser implementados, comparados bajo el mismo entorno experimental y evaluados de forma rigurosa.

4.1 Diseño Experimental

- Definición clara de:
  - Variables de entrada (representación y dimensiones).
  - Variable objetivo y horizonte de predicción (si aplica).
- División del dataset:

  - Entrenamiento / validación / prueba, con proporciones, semilla y estrategia de partición (aleatoria, estratificada, agrupada, temporal o espacial por bloques) justificada en el EDA.
  - Esquema de validación para selección de hiperparámetros: validación cruzada anidada o partición fija de validación, según el tamaño del dataset y la estructura de dependencia.
- Definición de pipeline:
  - Preprocesamiento (ajustado solo con el conjunto de entrenamiento).
  - Entrenamiento.
  - Evaluación.

Estudio piloto y dimensionamiento de la muestra. Antes de la ejecución definitiva de los tres modelos base, el equipo debe realizar un **estudio piloto** que permita estimar la variabilidad de la métrica primaria y dimensionar el número de ejecuciones. Sin este paso, el baseline no tiene sustento estadístico verificable.

- **Piloto:** al menos **cinco ejecuciones independientes** (semillas distintas) de cada uno de los tres modelos base, sobre la partición de validación. Reportar media, desviación estándar y coeficiente de variación de la métrica primaria.
- **Diferencia mínima de interés:** fijar el margen δ de relevancia práctica (ya declarado en la Sección 1) y expresarlo también en unidades de la desviación estándar de las diferencias pareadas, $\delta/\hat{\sigma}_d$.
- **Tamaño de muestra:** calcular el número de ejecuciones necesarias para detectar δ con potencia $1-\beta \geq 0{,}80$ y nivel $\alpha = 0{,}05$ mediante la aproximación

$$R \;\approx\; \frac{\left(z_{1-\alpha/2} + z_{1-\beta}\right)^2 \hat{\sigma}_d^2}{\delta^2},$$

  y reportar el resultado junto con el supuesto de normalidad de las diferencias pareadas (o la alternativa no paramétrica si no se cumple).
- **Diferencia mínima detectable:** con las ejecuciones realizadas, reportar la menor diferencia que el diseño puede detectar con potencia 0.80. Si es mayor que δ, el diseño debe ampliarse o declararse como limitación explícita.
- **Relación con el Entregable 2:** el valor $\hat{\sigma}_d$ estimado aquí se usará como punto de partida para el número de semillas del benchmark. No se considera definitivo.

- **Registro:** el piloto, sus supuestos y su resultado se documentan en un archivo de preregistro breve, fechado y previo a la ejecución definitiva.

4.2 Implementación de los Tres Modelos Base

- Implementar los tres modelos base identificados en la sección 3.2 con la configuración reportada en la literatura, o con una configuración mínima justificada.
- Entrenarlos con el **mismo pipeline, la misma partición y las mismas semillas**.
- Definición de hiperparámetros:
  - Learning rate y planificador.
  - Número de capas y unidades.
  - Batch size.
  - Optimizador, regularización (*dropout*, decaimiento de pesos) y función de pérdida.
- Estrategia de entrenamiento:
  - Número máximo de épocas.
  - *Early stopping* con criterio sobre el conjunto de validación.
- Registro de:
  - Curvas de entrenamiento y validación.
  - Número de parámetros.
  - Tiempo computacional y hardware empleado.
- **Equidad en la optimización:** los tres modelos base deben recibir el mismo esfuerzo de ajuste de hiperparámetros (mismo método de búsqueda, mismo presupuesto de evaluaciones y espacios de búsqueda comparables en amplitud), de modo que el baseline obtenido sea justo y no subestimado. Documentar el espacio de búsqueda y los valores seleccionados.
- Implementación desde cero o uso de librerías justificadas, con versiones de *software* registradas.

4.3 Requisitos Experimentales

- Control de semillas aleatorias (generadores de la librería, de números aleatorios y de las operaciones del dispositivo), declarando si se usa determinismo estricto.

- **Repetición de experimentos:** cada modelo base se ejecuta con semillas de inicialización independientes y documentadas. El número mínimo es **cinco ejecuciones independientes por modelo** (seis si se usan pruebas por rangos), y debe ajustarse al valor que resulte del **estudio piloto** de la Sección 4.1; si el análisis de potencia exige más ejecuciones, ese número prevalece. Cuando sea posible, combinar semillas distintas con particiones de validación distintas.
- Reporte de media, desviación estándar e intervalos de confianza.
- Uso de GPU (si aplica) documentado.
- Empaquetado reproducible: archivo de dependencias, *scripts* o cuadernos ejecutables de extremo a extremo y registro de configuración de cada corrida.

Buenas Prácticas Obligatorias

Prevención de Data Leakage (crítico)

- Separar completamente train/validation/test.
- Ajustar transformaciones (escalado, codificación, vocabulario, imputación, selección de atributos) solo en train.
- Evitar mezcla temporal en series de tiempo, regresión temporal y espacio-temporal.
- Evitar fuga espacial: validar por bloques con separación mayor al rango de autocorrelación.
- Evitar fuga de información semántica en NLP (duplicados, casi duplicados, mismo autor o documento en particiones distintas).
- Evitar fuga por agrupamiento en imágenes (mismo sujeto, sitio o escena en particiones distintas).
- Validación consistente entre los tres modelos base.
- El conjunto de prueba se evalúa una sola vez por corrida, con el modelo y los hiperparámetros ya fijados.

4.4 Evaluación

- **Definir métrica principal y métricas secundarias acordes al problema:**
  - **Clasificación (tabular, imágenes, texto):** Accuracy, Precision, Recall, F1-score

(macro, ponderado y por clase), AUC-ROC, AUC-PR (recomendada con desbalance), coeficiente de correlación de Matthews y calibración (error de calibración esperado, diagrama de fiabilidad).

- **Regresión (tabular, temporal, espacial, espacio-temporal) y series de tiempo:** RMSE, MAE, R^2; MAPE o sMAPE (con cautela ante valores cercanos a cero) y MASE para comparar entre series o contra un pronóstico ingenuo.
- **Series de tiempo:** reportar el error por horizonte de pronóstico y comparar con referencias ingenuas (persistencia y ingenuo estacional).
- **Regresión espacial y espacio-temporal:** errores globales y por ubicación o región, y autocorrelación espacial de los residuos (I de Moran sobre residuos).
- **Etiquetado secuencial:** precisión, exhaustividad y F1 a nivel de entidad (coincidencia exacta de *spans*), además de exactitud a nivel de *token*.
- **Secuencia a secuencia:** métricas de generación según la tarea (por ejemplo, BLEU, ROUGE, chrF o exactitud de secuencia completa), reportando la configuración exacta de cálculo (tokenización, versión de la implementación).
- **Segmentación de imágenes:**
  - **IoU (Intersection over Union):**

$$IoU = \frac{TP}{TP + FP + FN}$$

    donde TP, FP y FN corresponden a verdaderos positivos, falsos positivos y falsos negativos a nivel de píxel.
  - **Dice Coefficient (F1-score para segmentación):**

$$Dice = \frac{2TP}{2TP + FP + FN}$$

  - **Pixel Accuracy:** proporción de píxeles correctamente clasificados.
  - **Mean IoU (mIoU):** promedio del IoU sobre todas las clases.
  - **Boundary-based metrics (opcional):** evaluación de bordes para tareas donde la precisión espacial es crítica.

- **Comparación justa entre modelos base:**
  - Uso del mismo dataset y partición.
  - Mismo pipeline de preprocesamiento.
  - Misma configuración de evaluación.

- **Análisis de resultados:**
  - Reportar media, desviación estándar e intervalo de confianza (múltiples ejecuciones).
  - Descomposición de la varianza: variabilidad por semilla frente a variabilidad entre modelos.
  - Evaluación de robustez (por subgrupos, por nivel de ruido o ante perturbaciones controladas).
  - Diagnóstico de overfitting/underfitting mediante curvas de aprendizaje y brecha entre entrenamiento y validación.
  - Análisis de errores por segmentos relevantes (clase, rango del objetivo, ubicación, horizonte, longitud de la secuencia).
- **Análisis cualitativo:**
  - Visualización de predicciones frente a valores reales (o frente a *ground truth* en segmentación).
  - Identificación de errores sistemáticos y de casos difíciles.
  - Análisis de residuos (estructura, sesgo y heterocedasticidad).

5. Benchmark de los Modelos Base y Definición del Baseline

El benchmark debe ser **reproducible, justo y comparable**, e incluir de manera conjunta los tres modelos base. Su resultado es el **nivel mínimo de desempeño (baseline)** que deberá superar cualquier modelo avanzado propuesto en trabajos posteriores.

5.1 Comparación Tabular

- Tabla con:
  - Modelo base.
  - Métricas (media $\pm$ desviación estándar).
  - Intervalos de confianza (95 %), indicando el método de construcción (por ejemplo, t de Student o *bootstrap*).
  - Tiempo de entrenamiento y de inferencia.
  - Número de parámetros.

5.2 Ranking de Modelos Base

- Ordenar los tres modelos según la métrica principal del problema.
- Analizar trade-off:
  - Precisión vs costo computacional.
  - Precisión vs complejidad del modelo.

5.3 Definición del Baseline y Margen de Mejora Disponible

Este análisis es el objetivo central del entregable: determinar **cuál es el mejor modelo base y qué nivel de error o precisión establece como umbral mínimo** que debe superarse para que un modelo avanzado represente una mejora significativa y relevante.

- **Selección del baseline de referencia:**
  - Identificar el mejor modelo base según la métrica principal.
  - Reportar su desempeño con media, desviación estándar e intervalo de confianza al 95 %.
- **Cuantificación de las diferencias entre modelos base:**
  - **Regresión (incluida la temporal, espacial y espacio-temporal) y series de tiempo:** reducción relativa del error de cada modelo respecto al peor modelo base y respecto al mejor,

$$\Delta_{RMSE} = \frac{RMSE_{ref} - RMSE_{modelo}}{RMSE_{ref}} \times 100\,\%,$$

    y su equivalente para MAE.
  - **Clasificación, etiquetado secuencial y segmentación:** diferencia absoluta y relativa en la métrica principal (F1-score, AUC-ROC, F1 de entidad, mIoU o Dice) entre los modelos base.
  - **Secuencia a secuencia:** diferencia absoluta y relativa en la métrica principal de generación.
  - Acompañar cada diferencia con una **medida de tamaño de efecto** (por ejemplo, d de Cohen pareada o r de rango biserial).
- **Inferencia sobre las diferencias:**

- Comparaciones pareadas entre los tres modelos base, con corrección por múltiples comparaciones (Holm o Bonferroni).
- Reporte de la diferencia media, el intervalo de confianza al 95 % y el p-valor exacto (ajustado y sin ajustar).

- **Umbral de mejora para modelos avanzados:**
  - Definir, a partir de la variabilidad observada (desviación estándar entre corridas e IC al 95 %), la **mejora mínima detectable** que un modelo avanzado debería lograr respecto al mejor modelo base para considerarse estadísticamente distinguible del baseline.
  - Definir un **margen de relevancia práctica** (por ejemplo, reducción relativa mínima del error) justificado por el contexto de la aplicación y por la variabilidad intrínseca de los datos.
  - Contrastar el baseline con una cota de referencia del problema cuando exista (por ejemplo, ruido irreducible estimado, acuerdo entre anotadores o desempeño humano).
- **Interpretación:**
  - Distinguir entre diferencia estadísticamente significativa y diferencia prácticamente relevante entre los modelos base.
  - Valorar si el aumento en complejidad, número de parámetros y costo computacional entre los modelos base se traduce en mejoras de desempeño.
  - Concluir de manera explícita cuál es el baseline y qué margen de mejora queda disponible para modelos más avanzados.

5.4 Análisis Estadístico y Pruebas de Hipótesis

Se deben realizar **pruebas de hipótesis formales** para evaluar si las diferencias entre los modelos base son estadísticamente significativas. No se aceptan comparaciones basadas únicamente en promedios.

Comparación General entre Modelos Base (todos los tipos de problema)

- **Verificación de supuestos:** normalidad de las diferencias pareadas (Shapiro–Wilk y gráficos Q–Q), independencia y homogeneidad de varianzas. Justificar la elección entre prueba paramétrica y no paramétrica a partir de esta verificación.
- **Comparaciones pareadas:**

    - ***t*-test pareado** (con normalidad).
    - **Wilcoxon signed-rank test** (no paramétrico).
    - Las observaciones pareadas deben corresponder a la misma semilla, partición o bloque para ambos modelos.
- **Múltiples modelos (los tres modelos base):**
    - **ANOVA de medidas repetidas** (si se cumplen los supuestos).
    - **Friedman test** (recomendado), con la salvedad de potencia de la Sección 7.
    - **Post-hoc:**
        - Nemenyi test.
        - Corrección de Bonferroni o Holm.
- **Intervalos de confianza y tamaño de efecto:** *bootstrap* sobre las diferencias pareadas y tamaño de efecto asociado a cada comparación.
- **Advertencia sobre independencia:** las ejecuciones que comparten el conjunto de prueba no son estrictamente independientes; reconocer esta limitación y, cuando sea posible, usar validación cruzada repetida con corrección de varianza o remuestreo por bloques.
- **Reporte de potencia:** acompañar cada prueba de hipótesis con la potencia estimada o la diferencia mínima detectable del diseño.
- **Ausencia de significancia:** no interpretarla como equivalencia. Si se quiere afirmar que dos modelos base son equivalentes, usar TOST o ROPE con margen δ y reportarlo como análisis separado.
- **Tamaño del efecto:** reportar siempre junto con el p-valor (por ejemplo, δ de Cliff o d de Cohen según corresponda).

Caso Específico: Clasificación (tabular, imágenes y texto)

- **Test de DeLong:**
    - Comparación estadística entre curvas ROC correlacionadas (mismo conjunto de prueba).
    - Evaluación de diferencias significativas en AUC.
- **Test de McNemar:** comparación de tasas de error entre dos clasificadores sobre el mismo conjunto de prueba (con la corrección de continuidad o la versión exacta cuando las discordancias sean pocas).

- Reportar:
  - Diferencia de AUC y de la métrica principal.
  - p-valor exacto del test.
  - Intervalos de confianza.
- En problemas multiclase, aplicar DeLong de forma justificada (uno contra el resto, con corrección) o reportar la comparación mediante *bootstrap* estratificado.

Caso Específico: Series de Tiempo y Regresión Temporal

- **Test de Diebold–Mariano:**
  - Comparación de precisión predictiva entre modelos, para cada horizonte.
  - Usar la corrección para muestras pequeñas (Harvey–Leybourne–Newbold) y una función de pérdida coherente con la métrica principal.
- **Test BDS (Brock–Dechert–Scheinkman):**
  - Evaluación de independencia y no linealidad en residuos.
- **Test de Ljung–Box:**
  - Evaluación de autocorrelación en residuos, con los grados de libertad apropiados y varios rezagos.
- Interpretar los residuos: autocorrelación remanente o no linealidad sin explicar indican margen de mejora estructural para modelos más avanzados.

Caso Específico: Regresión (tabular, espacial y espacio-temporal)

- Comparación de errores mediante:
  - t-test o Wilcoxon sobre errores (RMSE, MAE) entre corridas.
  - Diebold–Mariano sobre los errores a nivel de observación de la partición de prueba, cuando las observaciones sean aproximadamente independientes.
- Evaluación de intervalos de confianza de las métricas (*bootstrap*).
- **Regresión espacial y espacio-temporal:** aplicar el I de Moran a los residuos de cada modelo; la autocorrelación espacial remanente invalida la independencia supuesta por las pruebas clásicas y debe tratarse con *bootstrap* por bloques espaciales.

Caso Específico: Segmentación de Imágenes

- Unidad de análisis: la imagen (no el píxel), pues los píxeles de una misma imagen están correlacionados; calcular Dice o IoU por imagen y comparar por pares con Wilcoxon o t-test pareado.
- *Bootstrap* sobre imágenes de prueba para los intervalos de confianza de mIoU y Dice.
- Comparar por clase, con corrección por múltiples comparaciones.

Caso Específico: Etiquetado Secuencial y Secuencia a Secuencia

- *Bootstrap* pareado sobre oraciones o documentos de prueba (remuestreo de las unidades, no de los *tokens*) para comparar F1 de entidad, BLEU, ROUGE o la métrica de generación empleada.
- Prueba de permutación pareada (aproximada) como alternativa no paramétrica para métricas a nivel de corpus.
- Reportar el intervalo de confianza de la diferencia y el p-valor exacto.

Buenas Prácticas Estadísticas

- Nivel de significancia: $\alpha = 0{,}05$, declarado antes de analizar los resultados.
- Reportar p-valores exactos (no solo < 0.05), ajustados y sin ajustar.
- Reportar intervalos de confianza y tamaños de efecto.
- Verificar supuestos (normalidad, independencia).
- Realizar múltiples ejecuciones (mínimo 5).
- Declarar con antelación la métrica principal y las comparaciones de interés, para evitar la exploración selectiva de resultados.

Interpretación

- Determinar si las diferencias entre modelos base son estadísticamente significativas.
- Distinguir entre significancia estadística y relevancia práctica.
- Evitar conclusiones basadas solo en métricas promedio.

5.5 Discusión Crítica

- ¿Cuál de los tres modelos base funciona mejor y por qué (sesgo inductivo, capacidad, regularización)?
- ¿Cuál generaliza mejor?
- ¿Las diferencias entre los modelos base son estadísticamente significativas y prácticamente relevantes?
- ¿Existe trade-off relevante entre desempeño y costo entre los modelos base?
- ¿Cuál es el baseline resultante y qué umbral de mejora debe superar un modelo avanzado para ser relevante en este problema?
- ¿Qué margen de mejora potencial sugiere la brecha reportada en la literatura frente al baseline obtenido, y qué tan creíble es dada la variabilidad medida?
- Amenazas a la validez: interna (fuga de datos, optimización desigual), externa (generalización a otros datasets o dominios) y de construcción (adecuación de las métricas).
- Limitaciones del estudio.
- Recomendaciones futuras.

No se aceptan conclusiones descriptivas. Toda afirmación debe estar respaldada por **evidencia estadística rigurosa**.

6. Guía de Procedimiento por Tipo de Problema

Esta sección indica, para cada tipo de problema admitido, **cómo proceder** en la partición, el preprocesamiento, la selección de modelos base, la función de pérdida, la evaluación y la inferencia. Siga únicamente la guía correspondiente a su proyecto. La ruta completa de cada tipo para el benchmark de 10 modelos se desarrolla en el Entregable 2.

6.1 Clasificación (datos tabulares)

- **Partición:** estratificada por clase; agrupada si existen múltiples registros por entidad (paciente, cliente, sitio). Validación cruzada anidada si el tamaño es reducido.
- **Preprocesamiento:** imputación, escalado y codificación ajustados solo en train; *embeddings* de entidades para categóricas de alta cardinalidad.

- **Modelos base típicos:** MLP superficial, MLP profundo regularizado, red residual tabular.
- **Pérdida:** entropía cruzada (ponderada o *focal* ante desbalance).
- **Evaluación:** F1 macro, AUC-ROC, AUC-PR, MCC, calibración.
- **Inferencia:** DeLong, McNemar, Friedman con post-hoc.
- **Referencia de contexto:** regresión logística, para dimensionar el margen.

6.2 Regresión (datos tabulares)

- **Partición:** aleatoria o agrupada; estratificar por cuantiles del objetivo si hay asimetría fuerte.
- **Preprocesamiento:** transformación del objetivo si es necesaria (invertir la transformación antes de calcular métricas); escalado robusto.
- **Modelos base típicos:** MLP superficial, MLP profundo regularizado, red residual tabular.
- **Pérdida:** error cuadrático, absoluto o Huber según las colas del objetivo.
- **Evaluación:** RMSE, MAE, R^2, análisis de residuos.
- **Inferencia:** t-test pareado o Wilcoxon, Friedman con post-hoc, Δ_{RMSE} con IC.
- **Referencia de contexto:** SVR lineal o regresión lineal regularizada.

6.3 Series de Tiempo

- **Partición:** cronológica estricta (entrenamiento $<$ validación $<$ prueba), con validación de origen móvil; ningún dato futuro en el ajuste de transformaciones.
- **Preprocesamiento:** ventanas deslizantes con longitud derivada de ACF/PACF; diferenciación o normalización calculadas con el pasado; imputación causal.
- **Modelos base típicos:** MLP sobre rezagos, RNN simple, LSTM o GRU de una capa, CNN 1D poco profunda.
- **Pérdida:** error cuadrático o absoluto, coherente con la métrica de evaluación; declarar la estrategia multi-paso.
- **Evaluación:** RMSE, MAE, MASE por horizonte y comparación con pronóstico ingenuo.
- **Inferencia:** Diebold–Mariano por horizonte, Ljung–Box y BDS sobre residuos, Friedman con post-hoc.

6.4 Regresión Temporal

- **Partición:** cronológica estricta con *embargo* igual al máximo rezago de las covariables; sin barajar.
- **Preprocesamiento:** construcción de rezagos de las **covariables** (no del objetivo); escalado ajustado solo con el pasado; verificación de que cada covariable está disponible al momento de predecir.
- **Modelos base típicos:** MLP sobre covariables con rezagos, LSTM o GRU sobre secuencias de covariables, CNN 1D poco profunda.
- **Pérdida:** error cuadrático, absoluto o Huber.
- **Evaluación:** RMSE, MAE, R^2; análisis de la autocorrelación de residuos (si es alta, reconsiderar el tipo de problema).
- **Inferencia:** Diebold–Mariano, Ljung–Box sobre residuos, Wilcoxon o t pareado sobre ejecuciones, Friedman con post-hoc.
- **Referencia de contexto:** regresión lineal regularizada con las mismas covariables rezagadas.

6.5 Regresión Espacial

- **Partición:** por bloques espaciales con *buffer* superior al rango del semivariograma; evitar partición aleatoria de puntos.
- **Preprocesamiento:** proyección de coordenadas, construcción de la matriz de vecindad o de la rejilla; estandarización ajustada solo en train.
- **Modelos base típicos:** MLP con coordenadas y covariables, MLP con *embeddings* posicionales, CNN sobre rejilla de vecindad.
- **Pérdida:** error cuadrático o absoluto.
- **Evaluación:** RMSE, MAE, R^2 por bloque y mapa de errores; I de Moran sobre residuos.
- **Inferencia:** comparación pareada por bloques de validación, *bootstrap* por bloques, Friedman con post-hoc.

6.6 Regresión Espacio-Temporal

- **Partición:** temporal estricta; adicionalmente, por bloques espaciales si el objetivo es generalizar a ubicaciones no observadas. Declarar cuál escenario se evalúa.

- **Preprocesamiento:** construcción de tensores o grafos con criterio de vecindad documentado; ventanas temporales; normalización por nodo o global (justificada) ajustada con el pasado de train.
- **Modelos base típicos:** LSTM o GRU global sobre ventanas con coordenadas, ConvLSTM, red convolucional sobre grafo o rejilla poco profunda.
- **Pérdida:** error cuadrático o absoluto, con enmascaramiento de datos faltantes.
- **Evaluación:** errores por horizonte, por ubicación y globales; I de Moran sobre residuos.
- **Inferencia:** Diebold–Mariano por horizonte y ubicación con corrección múltiple, Ljung–Box por serie, Friedman con post-hoc.

6.7 Clasificación de Imágenes

- **Partición:** estratificada y agrupada por sujeto, sitio o escena; eliminación previa de duplicados y casi duplicados.
- **Preprocesamiento:** *resizing* y normalización con estadísticos del conjunto de entrenamiento; *augmentations* aplicadas únicamente en train y que preserven la etiqueta.
- **Modelos base típicos:** CNN poco profunda, CNN pequeña con normalización por lotes, ResNet de baja profundidad.
- **Pérdida:** entropía cruzada (ponderada o *focal* ante desbalance).
- **Evaluación:** F1 macro, AUC-ROC, matriz de confusión, mapas de saliencia para análisis cualitativo.
- **Inferencia:** McNemar, DeLong, Friedman con post-hoc.

6.8 Segmentación de Imágenes

- **Partición:** por imagen, escena o sujeto, sin solapamiento entre parches de distintas particiones.
- **Preprocesamiento:** normalización con estadísticos de train; recorte en parches si la resolución lo requiere; *augmentations* geométricas y fotométricas aplicadas de forma consistente a imagen y máscara.
- **Modelos base típicos:** FCN sencilla, codificador–decodificador convolucional básico, U-Net reducida.
- **Pérdida:** Dice, entropía cruzada ponderada o combinación; *focal* o Tversky ante clases raras.

- **Evaluación:** mIoU, Dice, exactitud de píxel y métricas por clase; métricas de borde (opcional); visualización de predicciones frente a *ground truth*.
- **Inferencia:** Wilcoxon o t-test pareado sobre métricas por imagen, *bootstrap* sobre imágenes, Friedman con post-hoc.

6.9 Clasificación de Texto

- **Partición:** estratificada; agrupada por autor, fuente o hilo; eliminación previa de duplicados y casi duplicados entre particiones. En datos con deriva temporal, partición cronológica.
- **Preprocesamiento:** tokenización y construcción del vocabulario solo con train; longitud máxima derivada del EDA; manejo documentado de palabras fuera de vocabulario.
- **Modelos base típicos:** MLP sobre *embeddings* promediados, CNN de texto, LSTM o GRU de una capa.
- **Pérdida:** entropía cruzada (ponderada ante desbalance).
- **Evaluación:** F1 macro, AUC-ROC (o AUC-PR), matriz de confusión, análisis de errores por longitud y por clase.
- **Inferencia:** McNemar, *bootstrap* pareado sobre documentos, Friedman con post-hoc.

6.10 Etiquetado Secuencial

- **Partición:** por documento (no por oración); estratificación aproximada por frecuencia de etiquetas raras.
- **Preprocesamiento:** esquema de etiquetado consistente (BIO o BIOES), vocabulario de palabras y, si aplica, de caracteres, construidos solo con train.
- **Modelos base típicos:** LSTM o GRU bidireccional con clasificación por *token*, la misma con CRF, CNN dilatada.
- **Pérdida:** entropía cruzada por *token* (con enmascaramiento de *padding*) o verosimilitud condicional de secuencia (CRF).
- **Evaluación:** F1 a nivel de entidad (coincidencia exacta), precisión y exhaustividad por tipo de entidad, exactitud por *token*.
- **Inferencia:** *bootstrap* pareado sobre documentos, prueba de permutación, Friedman con post-hoc.

6.11 Aprendizaje Secuencia a Secuencia

- **Partición:** por documento o fuente, evitando pares repetidos o casi repetidos entre particiones; reportar desplazamiento de dominio si existe.
- **Preprocesamiento:** tokenización (palabra o subpalabra) aprendida solo con train; filtrado documentado de pares ruidosos o muy largos; vocabulario compartido o separado según el EDA.
- **Modelos base típicos:** codificador–decodificador con GRU o LSTM, el mismo con atención aditiva, codificador–decodificador convolucional sencillo.
- **Pérdida:** entropía cruzada por *token* con *teacher forcing* (con enmascaramiento de *padding*), con suavizado de etiquetas opcional.
- **Evaluación:** métrica de generación acorde a la tarea (BLEU, ROUGE, chrF o exactitud de secuencia completa), decodificación declarada (voraz o por haz, con tamaño del haz), análisis de errores por longitud.
- **Inferencia:** *bootstrap* pareado sobre ejemplos de prueba y prueba de permutación pareada; Friedman con post-hoc sobre semillas.

7. Limitaciones Inferenciales de Trabajar con Tres Modelos

Con solo tres modelos y cinco ejecuciones, varias pruebas del catálogo estadístico tienen **potencia muy baja**. Este entregable debe reconocerlo y tratarlo de forma explícita, en lugar de reportar p-valores como si las pruebas tuvieran poder suficiente.

- **Friedman con 3 modelos y 5 bloques:** el test tiene muy poca potencia y el post-hoc de Nemenyi es conservador. Una ausencia de significancia **no** demuestra equivalencia entre los modelos base.
- **Mínimo del Wilcoxon pareado:** con $n = 5$ pares, el p-valor exacto bilateral más pequeño posible es $2/2^5 = 0{,}0625$, mayor que 0,05. Con 5 ejecuciones **es imposible rechazar** H_0 con Wilcoxon bilateral a $\alpha = 0{,}05$, incluso si todas las diferencias van en la misma dirección. Por eso se recomienda usar al menos 6 ejecuciones para esa prueba, o reportar t pareado con verificación de normalidad, o *bootstrap* pareado.
- **Corrección de Holm con 3 comparaciones:** reduce aún más la potencia; el nivel ajustado más exigente es $\alpha/3 \approx 0{,}0167$.
- **Qué hacer:**

1. Usar **validación cruzada repetida** (por ejemplo 5×5) para obtener más observaciones pareadas, aplicando la corrección de varianza de Nadeau y Bengio.
2. Reportar la **diferencia mínima detectable** con el número de ejecuciones disponible.
3. Complementar con **tamaños de efecto con intervalo de confianza** (por *bootstrap*) y con la **probabilidad de superioridad**.
4. Para afirmar equivalencia entre dos modelos base, usar TOST o ROPE con el margen δ, no la ausencia de significancia.

- **Objetivo del entregable:** el propósito es **fijar el baseline** y su variabilidad con honestidad, no obtener significancia a toda costa. Un resultado "no concluyente" bien justificado y cuantificado es aceptable; un $p < 0{,}05$ obtenido con pruebas inapropiadas, no.

Entregables

- Informe en Jupyter Book.
- Código completo (EDA + tres modelos base + análisis estadístico), ejecutable de extremo a extremo y versionado.
- Dataset (o instrucciones exactas y *scripts* para su obtención cuando la licencia no permita redistribuirlo).
- Tabla de síntesis de la literatura con los modelos base extraídos y el diagrama de flujo del proceso de búsqueda.
- Tabla comparativa de los tres modelos base con métricas, definición del baseline e inferencia estadística.
- Archivo de dependencias, semillas y configuración de cada corrida.
- Declaración a priori de la métrica primaria, el margen δ, la unidad de independencia y la partición (insumo del Entregable 2).

Evaluación

Criterio	Peso
EDA	30 %
Revisión de literatura y extracción de los tres modelos base	30 %
Implementación de los tres modelos base	20 %
Benchmark, definición del baseline y análisis estadístico	20 %
Total	**100 %**

Buenas Prácticas

- Usar múltiples ejecuciones (mínimo 5; preferible 6 o más para pruebas por rangos).
- Reportar media, desviación estándar, IC 95 % y tamaño de efecto.
- Justificar las pruebas estadísticas utilizadas y verificar sus supuestos.
- Mantener consistencia experimental entre los tres modelos base.
- Documentar completamente el pipeline y garantizar su reproducibilidad.
- Declarar con antelación la métrica principal y el protocolo de evaluación.

Observación Final
Se espera un análisis exhaustivo: no solo comparar los tres modelos base, sino demostrar rigurosamente, mediante inferencia estadística, cuál es el baseline de desempeño para el problema seleccionado y qué margen de mejora debe superar un modelo avanzado para ser considerado una contribución significativa y relevante, reconociendo con honestidad las limitaciones de potencia de un diseño con tres modelos.